

Etapas 2 – Definição do Produto Analítico

1.1 Análise Inicial da Base de Dados

Após uma análise inicial dos dados obtidos por meio da plataforma Kaggle, identificou-se uma limitação significativa na riqueza das informações disponíveis, o que comprometeria a realização de uma análise exploratória mais aprofundada. Dessa forma, o projeto ficaria restrito, em grande parte, à aplicação de técnicas de Processamento de Linguagem Natural (NLP), limitando seu potencial analítico.

1.2 Substituição da Base de Dados

Diante desse cenário, optou-se pela substituição da base de dados por uma alternativa mais completa, obtida a partir de um repositório no GitHub, com o objetivo de ampliar as possibilidades de análise e enriquecer os resultados do projeto.

A nova base de dados apresenta um conjunto mais abrangente de variáveis, incluindo informações sobre o tipo de produto adquirido, localização e data da compra, além do conteúdo completo das avaliações realizadas pelos usuários. Essa maior diversidade de dados possibilita a exploração de diferentes abordagens analíticas, tornando o estudo mais robusto, detalhado e relevante.

1.3 Objetivo da Etapa

Nesta segunda etapa do projeto, o foco está direcionado ao processo de tratamento dos dados, bem como à realização de uma análise exploratória inicial, com o objetivo de compreender a estrutura da base e identificar possíveis caminhos para modelagem analítica.

1.4 Bibliotecas Utilizadas

Para o desenvolvimento das etapas de tratamento e análise dos dados, foi utilizada a linguagem de programação Python, em conjunto com bibliotecas amplamente empregadas na área de Ciência de Dados e visualização de informações.

As principais bibliotecas utilizadas foram:

- pandas: responsável pela leitura, manipulação e estruturação da base de dados
- numpy: utilizada para operações numéricas e suporte a cálculos vetoriais
- matplotlib: utilizada para a construção de gráficos, como histogramas e distribuições
- seaborn: utilizada para visualizações estatísticas mais elaboradas, como a análise da distribuição do tamanho das avaliações
- wordcloud: utilizada para geração de nuvem de palavras, permitindo a visualização das palavras mais frequentes nas avaliações dos usuários

A utilização dessas bibliotecas possibilita uma análise eficiente dos dados, facilitando a identificação de padrões, distribuição das variáveis e principais características textuais presentes na base.

1.5 Método Analítico Proposto

1.5.1 Técnica Selecionada: VADER

Para a realização da análise de sentimento das avaliações da Amazon, foi escolhida a técnica VADER (Valence Aware Dictionary and sEntiment Reasoner), devido à sua eficiência,

interpretabilidade e adequação ao contexto de textos curtos e informais, como reviews de produtos.

O VADER é um método baseado em léxico e regras gramaticais (heurísticas), desenvolvido especificamente para análise de sentimentos em mídias sociais, comentários e avaliações online.

A escolha dessa técnica se justifica pelos seguintes fatores:

- Adequação ao contexto de reviews
- Classificação em três categorias (positivo, neutro e negativo)
- Não necessidade de treinamento inicial
- Alta eficiência computacional

1.5.2 Fundamentação Teórica

O funcionamento do VADER está fundamentado em dois principais pilares:

a) Léxico de Sentimento

O modelo utiliza um dicionário onde cada palavra possui uma pontuação de valência, representando a intensidade do sentimento associado.

b) Heurísticas Gramaticais

O modelo aplica regras contextuais, como:

- Intensificadores (ex: “extremely”)
- Negações (ex: “not good”)
- Conjunções adversativas (ex: “but”)
- Pontuação e capitalização

1.5.3 Classificação de Sentimento

O modelo gera um compound score entre -1 e 1, sendo:

- Positivo: $\geq 0,05$
- Neutro: entre -0,05 e 0,05
- Negativo: $\leq -0,05$

1.5.4 Abordagem Aplicada ao Projeto

Considerando as variáveis `review_headline` e `review_body`, será realizada:

- Análise de sentimento separada para cada campo
- Comparação entre os resultados
- Possível combinação dos resultados por média ponderada

1.5.5 Técnica Alternativa: Transformers (BERT)

Como alternativa avançada, pode-se utilizar modelos baseados em Transformers, como o BERT, que utilizam mecanismos de atenção para compreender o contexto textual de forma mais profunda.

Apesar da maior precisão, esses modelos apresentam maior complexidade e custo computacional.

1.6 Dicionário de Dados

A seguir, apresenta-se o dicionário de dados da base utilizada:

Nome da Coluna	Descrição	Tipo de dado
marketplace	Local geográfico em que a compra foi realizada	Texto
customer_id	Identificador único do usuário (cliente) que realizou a compra do produto	Número
review_id	Chave primária da base. Identifica qual o ID da review realizada	Texto
product_id	Identificador do tipo de produto que foi adquirido pelo cliente	Texto
product_parent	Identificador numérico do tipo de produto que será adquirido	Número
product_title	Título descritivo simples do produto que foi comprado	Texto
product_category	Categoria do produto adquirido	Texto
star_rating	Classificação numérica de 1 a 5 dada como review do produto comprado	Número
helpful_notes	Quantidade de vezes que a review foi dada como 'helpful' por outros usuários	Número
total_votes	Quantidade de vezes que a review foi votada por outros usuários	Número
vine	Valor único (N) em todas as linhas. Não foi descoberto o significado deste campo	Texto
verified_purchase	Validação categórica (Y ou N) se a compra foi validada ao longo do processo	Texto
review_headline	Título (simples) da review realizada pelo cliente	Texto
review_body	Review completa realizada pelo cliente. Há caracteres especiais e emoticons, por exemplo.	Texto
review_date	Data (YYYY-MM-DD) de quando foi realizada a review	Data
sentiment	Marcação inicial do resultado de análise de sentimento feita pelo dono da base (coluna será jogada fora)	Número

Além disso, as responsabilidades da equipe e o cronograma do projeto foram reavaliados, de modo a incorporar os ajustes necessários decorrentes da substituição da base de dados, conforme apresentado a seguir.

1.7 Matriz RACI

	Henrique	Igor	Luiz
Definição do escopo	R	A	C
Obtenção dos dados	A	R	C
Análise exploratória	C	R	A
Definição do modelo	A	C	R
Cálculo de acurácia	R	A	C
Identificação de oportunidades	C	A	R
Data storytelling	R	C	A
Apresentação final	C	R	A
Documentação	A	C	R

1.8 Novo Cronograma

