

Projeto Aplicado II – Bancos de Dados – 2026.1

Henrique Sarmento – 10738262

Luiz Berlandi Neto – 10724617

Igor Eduardo Dallan do Couto – 10748144

Etapa 3 – Apresentação de Produtos e Storytelling

1. Consolidação dos Resultados do Método Analítico

Nesta etapa, foram consolidados os resultados obtidos a partir da aplicação do algoritmo VADER (Valence Aware Dictionary and sEntiment Reasoner) de classificação de sentimentos à base de dados de avaliações do produto Fire HD 7 (Amazon). O pré-processamento incluiu remoção de HTML e caracteres especiais.

O VADER não é um modelo de aprendizado de máquina que "aprende" lendo textos; ele funciona combinando um léxico (um dicionário mapeado) com regras gramaticais (heurísticas).

- **Léxico de Valência:** Pesquisadores avaliaram milhares de palavras e atribuíram a elas uma nota (valência) que vai do extremamente negativo ao extremamente positivo. Por exemplo, a palavra *good* tem uma pontuação base positiva (+1.9), enquanto *bad* tem uma pontuação negativa (-2.5).
- **Heurísticas de Contexto:** O algoritmo não olha apenas para as palavras isoladas. Ele ajusta matematicamente a pontuação base se encontrar intensificadores (*very good* aumenta a nota), negações (*not good* inverte a nota), letras maiúsculas (*GOOD* aumenta a intensidade) ou excesso de pontuação (*good!!!!*).

Após varrer a frase, identificar as palavras do dicionário e aplicar os multiplicadores gramaticais, o VADER soma todas essas pontuações individuais chegando a um valor 'x'.

Como essa soma bruta pode ser qualquer número (dependendo do tamanho do texto), o VADER precisa comprimir esse valor para que o resultado sempre caia em uma escala padronizada entre -1 (totalmente negativo) e 1 (totalmente positivo). Para isso, ele aplica uma fórmula de normalização geométrica:

$$Compound = \frac{x}{\sqrt{x^2 + \alpha}}$$

- x é a soma total das valências de todas as palavras processadas no texto.
- α (alfa) é uma constante matemática de normalização. No código-fonte do VADER, esse valor é fixado em 15. Esse número foi escolhido porque estabiliza a curva da equação de forma ideal para o número de palavras que compõem uma frase comum.

Além disto, para ser capaz de avaliar a eficácia do método aplicado, também é necessário compará-lo a um *ground truth* que será obtido através do campo *star_rating* com a nota de 1 a 5 dada pelo usuário. Ou seja, neste conjunto de dados de avaliações, o texto digitado pelo cliente (*review_headline* e *review_body*) representa a variável que o VADER tentou adivinhar. O *star_rating* (as estrelas que o cliente clicou) representa o gabarito real daquele sentimento. O cálculo da acurácia ocorre em duas etapas:

- Alinhamento de Escalas: Primeiro, transformamos a métrica quantitativa das estrelas na mesma escala categórica do VADER. Avaliações de 1 e 2 estrelas são mapeadas como o gabarito "NEGATIVO"; 3 estrelas como "NEUTRO"; e 4 e 5 estrelas como o gabarito "POSITIVO".
- Cruzamento e Cálculo: Nosso script compara a classificação gerada pelo modelo (baseada no Compound) com a classificação real das estrelas, linha por linha. Se o VADER previu "POSITIVO" e o cliente deu 5 estrelas, registra-se um acerto.

A matemática da acurácia geral é a proporção simples entre os sucessos do modelo e o universo de dados avaliados:


$$Acurácia = \frac{Total\ de\ previsões\ corretas}{Total\ de\ avaliações\ analisadas}$$

Se esse cálculo resultar em 0,80, significa que a pontuação gerada pela fórmula do VADER conseguiu deduzir com sucesso a nota real que o cliente da Amazon deu para o produto em 80% dos casos.

Para garantir melhor acurácia, além de analisar as colunas *review_headline* e *review_body*, também unificamos as duas para gerar uma coluna consolidada chamado *sentimento_geral*. Desta forma garantimos que estamos olhando de fato para todos os dados disponíveis de forma unificada.

1.1 Resultados Consolidados

Após a devida aplicação do modelo VADER, chegamos nos seguintes resultados:



Para o cálculo da acurácia, utilizamos da seguinte classificação:

- $Star_rating \geq 4$: Positivo
- $Star_rating \leq 3$: Negativo
- Resto: Neutro

Finalmente, temos os resultados de acurácia de cada possibilidade:

	headline	body	geral
Acurácia	43,59%	81,99%	83,42%

1.2 Análise dos Resultados

Como era de se esperar, analisar o sentimento somente do título do review realizado é incorreto e trouxe a menor acurácia com 44% de acerto. Felizmente, conforme mais informação é agregada e disponibilizada no corpo da review a acurácia praticamente dobra para 82%. E ao agregar ambos o título e corpo, conseguimos aumentar um pouco mais a acurácia para 83,4%, apesar de ser um sutil acréscimo, ele comprova que havia palavras importantes sendo utilizadas no título que precisavam de contexto para poder atingir o resultado do seu valor composto mais próximo do esperado pelo *star_rating*.

3. Descrição dos Resultados Preliminares e Modelo de Negócios

3.1 Produto Gerado

O produto analítico desenvolvido é um classificador automático de sentimentos em avaliações de produtos da Amazon, capaz de identificar se uma review é positiva ou negativa com base no texto fornecido pelo cliente.

O pipeline do produto envolve: (1) ingestão do texto da avaliação; (2) pré-processamento (remoção de HTML e caracteres especiais); (3) classificação via VADER; (4) retorno do sentimento (Positivo/Neutro/Negativo) com score de confiança.

3.2 Rascunho do Modelo de Negócios

Proposta de valor: oferecer às empresas uma ferramenta de monitoramento contínuo da satisfação de clientes por meio da análise automática de reviews, permitindo identificação ágil de problemas de qualidade e oportunidades de melhoria.

- Segmento de clientes: e-commerces, fabricantes de eletrônicos, plataformas de marketplace.
- Canais: API REST integrável a plataformas de e-commerce; dashboard web com visualizações em tempo real.
- Receita: modelo SaaS com cobrança por volume de avaliações processadas mensalmente.
- Recursos-chave: modelo treinado (VADER), infraestrutura de dados e equipe de ciência de dados.
- Parceiros: provedores de cloud (AWS/GCP), plataformas de avaliações de produtos.

4. Esboço do Storytelling

4.1 Narrativa Central

O storytelling do projeto segue a estrutura: Contexto → Conflito → Resolução.

Contexto: Empresas recebem milhares de avaliações de clientes diariamente. Ler e interpretar manualmente esse volume de dados é impossível. Como identificar rapidamente quando os clientes estão insatisfeitos?

Conflito: A base de avaliações da Amazon para o Fire HD 7 contém 30.846 reviews. Sem um método automático, 5.079 avaliações negativas (16,5%) poderiam passar despercebidas entre a maioria positiva.

Resolução: Ao aplicar o modelo VADER, foi possível classificar automaticamente 83,4% das avaliações corretamente. O modelo entrega um instrumento prático para monitoramento da satisfação do consumidor em escala.

4.2 Elementos Visuais Planejados

- Gráfico de pizza: distribuição de sentimentos positivos vs. negativos.
- Matriz de confusão: visualização do desempenho do VADER.
- Nuvem de palavras: termos mais frequentes em avaliações positivas e negativas.
- Linha do tempo: evolução do sentimento médio ao longo das datas de avaliação.

4.3 Público-alvo da Apresentação

A apresentação será direcionada a gestores de produto e times de customer experience, com linguagem acessível, priorizando insights de negócio sobre detalhes técnicos dos algoritmos.

5. Matriz RACI e Cronograma

5.1 Matriz RACI

Atividade	Henrique	Igor	Luiz
Definição do escopo	R	A	C
Obtenção dos dados	A	R	C
Análise exploratória	C	R	A
Definição do modelo	A	C	R
Cálculo de acurácia	R	A	C
Identificação de oportunidades	C	A	R
Data storytelling	R	C	A
Apresentação final	C	R	A
Documentação	A	C	R

5.2 Cronograma

	16/mar	30/mar	13/abr	27/abr	11/mai	25/mai
Definição do escopo						
Obtenção dos dados						
Análise exploratória						
Definição do modelo						
Cálculo de acurácia						
Identificação de oportunidades						
Data storytelling						
Apresentação final						
Documentação						