

Henrique Sarmento – 10738262

Luiz Berlandi Neto – 10724617

Igor Eduardo Dallan do Couto – 10748144

1. INTRODUÇÃO

1.1 Contexto do Projeto

Este projeto foi desenvolvido como parte de um pipeline de análise de dados textuais, com foco na avaliação da percepção dos clientes sobre produtos da Amazon. O objetivo principal foi aplicar técnicas de **Processamento de Linguagem Natural (PLN)** para classificar automaticamente o sentimento de avaliações de usuários, utilizando o algoritmo **VADER (Valence Aware Dictionary and sEntiment Reasoner)**, e comparar os resultados com as classificações baseadas em notas (star ratings).

1.2 Objetivos Específicos

- Realizar uma **Análise Exploratória de Dados (EDA)** completa do dataset.
- Aplicar o modelo VADER em três diferentes níveis de análise (título, corpo e texto completo).
- Avaliar a acurácia do modelo em comparação com um gabarito baseado nas estrelas.
- Identificar limitações do modelo e propor melhorias.

1.3 Ferramentas e Tecnologias Utilizadas

Categoria	Ferramentas
Linguagem	Python 3.13
Manipulação de dados	Pandas, NumPy
Visualização	Matplotlib, Seaborn, WordCloud
PLN	NLTK (VADER)
Métricas	Scikit-learn (accuracy_score, classification_report)
Ambiente	Jupyter Notebook

2. METODOLOGIA

2.1 Estrutura do Dataset

O dataset `appl_1_amazon_pc.csv` contém **30.846 avaliações** de clientes Amazon para o produto **Fire HD 7** (categoria PC). A tabela abaixo descreve as principais colunas utilizadas:

Coluna	Tipo	Descrição
<code>star_rating</code>	<code>int64</code>	Nota de 1 a 5 estrelas
<code>review_headline</code>	<code>string</code>	Título da avaliação
<code>review_body</code>	<code>string</code>	Texto completo da avaliação
<code>verified_purchase</code>	<code>string</code>	Indica se a compra foi verificada
<code>helpful_votes</code>	<code>int64</code>	Número de votos úteis
<code>review_date</code>	<code>string</code>	Data da avaliação

2.2 Pré-processamento dos Dados

```
python
```

```
# Remoção de valores nulos
```

```
data = data.dropna()
```

```
# Remoção da coluna original de sentimento
```

```
data = data.drop('sentiment', axis=1)
```

```
# Criação de coluna auxiliar
```

```
data['review_length'] = data['review_body'].str.len()
```

Justificativas:

- A remoção da coluna `sentiment` original foi necessária para evitar viés na avaliação do VADER.
- A coluna `review_length` foi criada para análise exploratória da distribuição do tamanho dos textos.

2.3 Análise Exploratória de Dados (EDA)

2.3.1 Distribuição das Estrelas

```
python
```

```
plt.hist(data['star_rating'], bins=5)
```

Nota Quantidade Percentual

5	20.017	64,9%
4	5.746	18,6%
3	2.216	7,2%
2	1.154	3,7%
1	1.707	5,5%

Análise: O dataset apresenta um **viés positivo significativo**, com mais de 83% das avaliações sendo 4 ou 5 estrelas. Isso impacta diretamente a avaliação do modelo, pois há muito mais exemplos positivos do que negativos.

2.3.2 Distribuição do Comprimento dos Textos

python

```
sns.histplot(data['review_length'], bins=50)
```

```
plt.xlim(0, 1000)
```

- **Média:** ~450 caracteres
- **Mediana:** ~320 caracteres
- **Textos muito longos** (>5000 caracteres) são raros (menos de 1% do total)

Implicação: O VADER é otimizado para textos curtos (como tweets e avaliações), o que é adequado para este dataset.

2.3.3 Nuvem de Palavras (WordCloud)

Foram geradas nuvens de palavras para:

- review_headline
- review_body

Palavras mais frequentes:

- *love, great, good, like, amazon, fire, kindle, tablet, easy, use*

Insight: Os termos mais comuns são majoritariamente positivos, confirmando o viés observado na distribuição das estrelas.

3. APLICAÇÃO DO MODELO VADER

3.1 O que é o VADER?

VADER é um modelo de análise de sentimentos **baseado em léxico e regras**, desenvolvido especificamente para textos de redes sociais e avaliações curtas. Ele considera:

- **Intensidade das palavras** (ex: "good" vs "great")
- **Modificadores de intensidade** (ex: "very good", "not good")
- **Pontuação e emojis** (ex: "♡", "!!!")

A saída principal é o **compound score**, variando de -1 (negativo extremo) a +1 (positivo extremo).

3.2 Campos Analisados

Campo	Descrição
headline_sentimento	Apenas o título da avaliação
body_sentimento	Apenas o texto completo
sentimento_geral	Concatenação de título + texto

4. RESULTADOS E AVALIAÇÃO

4.1 Gabarito de Referência

Para avaliar o modelo, foi criada uma coluna `sentimento_real` com base na `star_rating`:

```
python
```

```
def mapear_estrelas_para_sentimento(nota):
```

```
    if nota >= 4: return 'POSITIVO'
    elif nota <= 3: return 'NEGATIVO'
    else: return 'NEUTRO'
```

Distribuição do gabarito:

- **POSITIVO:** 25.763 (83,5%)
- **NEGATIVO:** 5.077 (16,5%)
- **NEUTRO:** 0 (0%)

4.2 Métricas de Desempenho

4.2.1 Body (texto completo)

Classe	Precisão	Recall	F1-score	Suporte
--------	----------	--------	----------	---------

POSITIVO	0,91	0,90	0,90	25.763
----------	------	------	------	--------

NEGATIVO	0,65	0,43	0,51	5.077
----------	------	------	------	-------

NEUTRO	0,00	0,00	0,00	0
--------	------	------	------	---

Acurácia: 81,99%

4.2.2 Headline (apenas título)

Acurácia: 43,59%

4.2.3 Sentimento Geral (título + texto)

Classe	Precisão	Recall	F1-score	Suporte
--------	----------	--------	----------	---------

POSITIVO	0,91	0,91	0,91	25.763
----------	------	------	------	--------

NEGATIVO	0,67	0,44	0,53	5.077
----------	------	------	------	-------

NEUTRO	0,00	0,00	0,00	0
--------	------	------	------	---

Acurácia: 83,42%

4.3 Análise dos Resultados

4.3.1 Pontos Fortes

- **Excelente performance para sentimentos positivos** (precisão e recall acima de 90%).
- **A combinação título + texto** (sentimento_geral) apresentou a melhor acurácia (83,42%).
- O modelo é **rápido e não requer treinamento**, sendo adequado para aplicações em tempo real.

4.3.2 Limitações Identificadas

- **Baixa sensibilidade para sentimentos negativos** (recall de apenas 43-44%).
- **Nenhuma classificação neutra** — o VADER tende a polarizar textos mesmo quando são ambíguos.
- O **viés positivo do dataset** favorece a classe majoritária, mascarando a real capacidade do modelo em detectar críticas.

4.3.3 Matriz de Confusão (Body vs Real)

Real \ Previsto POSITIVO NEGATIVO

POSITIVO	23.186	2.577
NEGATIVO	2.893	2.184

Interpretação:

- 2.577 avaliações positivas foram classificadas erroneamente como negativas (falsos negativos).
 - 2.893 avaliações negativas foram classificadas erroneamente como positivas (falsos positivos).
-

5. VISUALIZAÇÃO DOS RESULTADOS

python

```
fig, axes = plt.subplots(1, 3, figsize=(18, 6))
```

```
sns.countplot(data=data, x='headline_sentimento', ax=axes[0],  
order=ordem_categorias, palette=cores)
```

```
sns.countplot(data=data, x='body_sentimento', ax=axes[1],  
order=ordem_categorias, palette=cores)
```

```
sns.countplot(data=data, x='sentimento_geral', ax=axes[2],  
order=ordem_categorias, palette=cores)
```

Principais observações visuais:

- A distribuição dos sentimentos detectados pelo VADER é extremamente polarizada (quase 100% positivo).
 - Não há barras para a classe neutra em nenhum dos gráficos.
 - O comportamento entre headline, body e sentimento geral é visualmente idêntico.
-

6. CONCLUSÕES E RECOMENDAÇÕES

Conclusões

1. O **VADER é eficaz para detectar sentimentos positivos** (91% de precisão), mas falha em capturar adequadamente sentimentos negativos.
2. A **combinação de título e texto** produz os melhores resultados (83,42% de acurácia).

3. O **viés positivo do dataset** é um fator limitante — mesmo um modelo perfeito teria dificuldade em avaliar negativos devido ao desbalanceamento das classes.
4. O VADER **não classifica nenhum texto como neutro** neste dataset, o que pode ser inadequado para aplicações que exigem detecção de neutralidade.

Recomendações para Trabalhos Futuros

Recomendação	Justificativa
Balanceamento do dataset	Coletar mais exemplos negativos ou usar técnicas de oversampling/undersampling
Testar outros modelos	BERT, RoBERTa, ou TextBlob podem ter melhor performance para negativos
Ajustar limiares do VADER	Reduzir o threshold para negativo (ex: -0.01) pode aumentar o recall
Pré-processamento avançado	Remover stopwords, aplicar stemming/lemmatização
Avaliação por produto	O dataset contém apenas um produto; testar com múltiplos produtos validaria a generalização

7. REFERÊNCIAS

- Hutto, C.J. & Gilbert, E.E. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text. *Eighth International Conference on Weblogs and Social Media (ICWSM-14)*.
- NLTK Project. (2024). Natural Language Toolkit documentation.
- Scikit-learn: Machine Learning in Python, Pedregosa et al., JMLR 12, pp. 2825-2830, 2011.

8. LINK DE APOIO

<https://youtu.be/dMfYLQuerv8>

<https://github.com/henri-sarmiento/ProjetoAplicado2>